

Teoria da Decisão

Métodos Escalares de Otimização Vetorial

Prof. Lucas S. Batista

lusoba@ufmg.br

www.ppggee.ufmg.br/~lusoba

Universidade Federal de Minas Gerais
Escola de Engenharia
Graduação em Engenharia de Sistemas

Sumário

1 Métodos escalares clássicos

- Apresentação
- Métodos escalares

Problema de otimização multiobjetivo

- Formulação geral do problema de otimização multiobjetivo (P_0):

$$\min_{\mathbf{x}} \mathbf{f}(\mathbf{x}) \in \mathbb{R}^m, \quad \mathbf{x} \in \mathcal{F}$$

$$\mathbf{f} : \mathcal{X} \subset \mathbb{R}^n \mapsto \mathcal{Y} \subset \mathbb{R}^m$$

$$\mathcal{F} = \begin{cases} g_i(\mathbf{x}) \leq 0; & i = 1, \dots, p \\ h_j(\mathbf{x}) = 0; & j = 1, \dots, q \\ \mathbf{x} \in \mathcal{X} \end{cases}$$

Métodos escalares/agregação

- Método da soma ponderada (*weighted-sum*);
- Método ϵ -restrito;

Sumário

1 Métodos escalares clássicos

- Apresentação
 - Métodos escalares

Método da soma ponderada (*weighted-sum*)

- Esta é a abordagem mais óbvia e “ingênua” para a solução de problemas de otimização multiobjetivo.
- O problema multiobjetivo original é transformado num problema mono-objetivo, podendo ser resolvido por qualquer método de otimização não linear.
- A estratégia mais simples emprega uma soma ponderada dos objetivos.

Método da soma ponderada (*weighted-sum*)

Formulação

Seja o problema P_0 . Este é transformado na formulação P_w a seguir:

$$\min_{\mathbf{x}} \mathbf{w}' \mathbf{f}(\mathbf{x}) = \sum_{i=1}^m w_i f_i(\mathbf{x})$$

$$\mathcal{F} = \begin{cases} g_i(\mathbf{x}) \leq 0; & i = 1, \dots, p \\ h_j(\mathbf{x}) = 0; & j = 1, \dots, q \\ \mathbf{x} \in \mathcal{X} \end{cases}$$

com $w_i \geq 0$ e $\sum_k w_k = 1$.

Método da soma ponderada (*weighted-sum*)

Normalização

Se as funções objetivo possuem diferentes semânticas ou significados, uma normalização é necessária:

$$f_i(\mathbf{x}) = \frac{f_i(\mathbf{x}) - \min_{\mathbf{x} \in \mathcal{F}} f_i(\mathbf{x})}{\max_{\mathbf{x} \in \mathcal{F}} f_i(\mathbf{x}) - \min_{\mathbf{x} \in \mathcal{F}} f_i(\mathbf{x})} \quad (\text{se minimização})$$

ou

$$f_i(\mathbf{x}) = \frac{\max_{\mathbf{x} \in \mathcal{F}} f_i(\mathbf{x}) - f_i(\mathbf{x})}{\max_{\mathbf{x} \in \mathcal{F}} f_i(\mathbf{x}) - \min_{\mathbf{x} \in \mathcal{F}} f_i(\mathbf{x})} \quad (\text{se maximização})$$

Método da soma ponderada (*weighted-sum*)

No caso de duas funções objetivo, temos:

$$\min_{\mathbf{x}} w_1 f_1(\mathbf{x}) + w_2 f_2(\mathbf{x})$$

No espaço de objetivos, esse problema corresponde a encontrar a menor constante C possível da equação a seguir:

$$f_2(\mathbf{x}) = -\frac{w_1}{w_2} f_1(\mathbf{x}) + C$$

Método da soma ponderada (*weighted-sum*)

Exemplo

Problema de Schaffer:

$$\min \mathbf{f} = \begin{cases} f_1(x) = x^2 \\ f_2(x) = (x - 2)^2 \end{cases}$$

$$\text{s.a: } x \in [0, 2]$$

- (a) Esboce o conjunto solução no espaço de decisão.
- (b) Aplique as condições de suficiência ao problema ponderado e mostre que as soluções de (a) são eficientes (Pareto-ótimas).
- (c) Obtenha amostras da fronteira Pareto-ótima para diferentes valores de ponderação.

Método da soma ponderada (*weighted-sum*)

- Em um problema de otimização linear (PL, PLI, PLIM) biobjetivo, é possível gerar todas as soluções Pareto-ótimas com o procedimento a seguir:

Passo 1: Resolver

$$\mathbf{z}_i = \arg \min \mathbf{c}'_i \mathbf{x}, \mathbf{x} \in \mathcal{F}$$

Passo 2: Faça $\lambda_1 = f_2(\mathbf{z}_1) - f_2(\mathbf{z}_2)$ e $\lambda_2 = f_1(\mathbf{z}_2) - f_1(\mathbf{z}_1)$;

Passo 3: Resolva $\mathbf{z} = \arg \min \lambda_1 \mathbf{c}'_1 \mathbf{x} + \lambda_2 \mathbf{c}'_2 \mathbf{x}, \mathbf{x} \in \mathcal{F}$ encontrando uma solução intermediária entre $(\mathbf{z}_1, \mathbf{z}_2)$;

Passo 4: Retorne ao passo 2, encontrando soluções intermediárias entre $(\mathbf{z}_1, \mathbf{z})$ e $(\mathbf{z}, \mathbf{z}_2)$.

Método da soma ponderada (*weighted-sum*)

- Seja o problema biobjetivo com funções quadráticas:

$$f_1(\mathbf{x}) = (\mathbf{x} - \mathbf{c}_1)'(\mathbf{x} - \mathbf{c}_1)$$

$$f_2(\mathbf{x}) = (\mathbf{x} - \mathbf{c}_2)'(\mathbf{x} - \mathbf{c}_2)$$

$$wf_1(\mathbf{x}) + (1 - w)f_2(\mathbf{x})$$

↓

$$(\mathbf{x} - [w\mathbf{c}_1 + (1 - w)\mathbf{c}_2])'(\mathbf{x} - [w\mathbf{c}_1 + (1 - w)\mathbf{c}_2]) + w(1 - w)(\mathbf{c}_1 - \mathbf{c}_2)'(\mathbf{c}_1 - \mathbf{c}_2)$$

- Variando os pesos, o mínimo da soma ponderada se desloca ao longo da reta que une os mínimos de f_1 e f_2 .

Método da soma ponderada (*weighted-sum*)

- No caso de funções quadráticas gerais:

$$f_1(\mathbf{x}) = (\mathbf{x} - \mathbf{c}_1)' \mathbf{A}_1 (\mathbf{x} - \mathbf{c}_1)$$

$$f_2(\mathbf{x}) = (\mathbf{x} - \mathbf{c}_2)' \mathbf{A}_2 (\mathbf{x} - \mathbf{c}_2)$$

$$wf_1(\mathbf{x}) + (1 - w)f_2(\mathbf{x})$$

↓

$$w\nabla f_1 + (1 - w)\nabla f_2 = 0$$

$$w\mathbf{A}_1(\mathbf{x} - \mathbf{c}_1) + (1 - w)\mathbf{A}_2(\mathbf{x} - \mathbf{c}_2) = 0$$

$$\mathbf{x} = [w\mathbf{A}_1 + (1 - w)\mathbf{A}_2]^{-1} [w\mathbf{A}_1\mathbf{c}_1 + (1 - w)\mathbf{A}_2\mathbf{c}_2]$$

Método da soma ponderada (*weighted-sum*)

Discussão

- Método simples e fácil de programar;
- Gera todas as soluções do conjunto Pareto somente se o conjunto solução de P_0 possuir imagem convexa;
- Várias ponderações podem levar à mesma solução eficiente;
- Em problemas com muitos objetivos, fica difícil controlar a diversidade do conjunto de soluções encontrado;
- O problema ponderado possui a mesma estrutura de restrições do problema original;
- Técnicas de programação matemática e metaheurísticas são aplicáveis.

Método ϵ -restrito

- Essa abordagem transforma o problema multiobjetivo em um problema mono-objetivo com restrições adicionais;
- Um dos objetivos é escolhido para ser minimizado;
- Os demais objetivos são transformados em restrições de desigualdade.

Método ϵ -restrito

Formulação

Seja o problema P_0 . Este é transformado na formulação P_ϵ a seguir:

$$\min_{\mathbf{x}} f_1(\mathbf{x})$$

$$\mathcal{F} = \begin{cases} f_k(\mathbf{x}) \leq \epsilon_k; & k = 2, \dots, m \\ g_i(\mathbf{x}) \leq 0; & i = 1, \dots, p \\ h_j(\mathbf{x}) = 0; & j = 1, \dots, q \\ \mathbf{x} \in \mathcal{X} \end{cases}$$

Método ϵ -restrito

- Por exemplo, com dois objetivos:

$$\min_{\mathbf{x}} f_1(\mathbf{x})$$

$$\mathcal{F} = \begin{cases} f_2(\mathbf{x}) \leq \epsilon \\ g_i(\mathbf{x}) \leq 0; & i = 1, \dots, p \\ h_j(\mathbf{x}) = 0; & j = 1, \dots, q \\ \mathbf{x} \in \mathcal{X} \end{cases}$$

Método ϵ -restrito

- Por exemplo, com três objetivos:

$$\min_{\mathbf{x}} f_1(\mathbf{x})$$

$$\mathcal{F} = \begin{cases} f_2(\mathbf{x}) \leq \epsilon_2 \\ f_3(\mathbf{x}) \leq \epsilon_3 \\ g_i(\mathbf{x}) \leq 0; \quad i = 1, \dots, p \\ h_j(\mathbf{x}) = 0; \quad j = 1, \dots, q \\ \mathbf{x} \in \mathcal{X} \end{cases}$$

Método ϵ -restrito

Exemplo

Problema de Schaffer:

$$\min \mathbf{f} = \begin{cases} f_1(x) = x^2 \\ f_2(x) = (x - 2)^2 \leq \epsilon \end{cases}$$

$$\text{s.a: } x \in [0, 2]$$

- (a) Esboce o conjunto solução no espaço de decisão.
- (b) Obtenha amostras da fronteira Pareto-ótima para diferentes valores de ϵ .

Método ϵ -restrito

Discussão

- A variação dos ϵ_k gera soluções Pareto-ótimas;
- Soluções associadas a trechos não convexos da fronteira Pareto podem ser alcançadas;
- Pode gerar pontos em trechos específicos da fronteira;
- Pode gerar pontos não pertencentes à fronteira Pareto-ótima;
- Quando o número de objetivos aumenta ($m > 2$), aumenta também a probabilidade de serem gerados problemas infactíveis;
- Aumenta o número de restrições do problema original;
- Em geral, fica difícil controlar a distribuição do conjunto de soluções encontradas;
- Técnicas de programação matemática e metaheurísticas são aplicáveis.

Algoritmo geral

Algoritmo 1: Protótipo geral de métodos escalares

Input: Funções objetivo e restrições $f(\cdot)$, $g(\cdot)$, $h(\cdot)$

- 1 **while** conjunto de estimativas não for satisfatório **do**
 - 2 | Gerar solução inicial \mathbf{x}_0 ;
 - 3 | Escolher formulação P_w ou P_ϵ ;
 - 4 | Resolver usando um método de otimização adequado;
 - 5 **end**
-

Questão

O processo de tomada de decisão pode ser *a priori*, progressivo (iterativo), ou *a posteriori*.

Em quais dessas classes os métodos escalares podem ser aplicados?

Literatura Especializada

-  Y. Collette, P. Siarry, Multiobjective Optimization: Principles and Case Studies, ser. Decision Engineering, Springer, 2003.
-  V. Chankong, Y. Haimes, Multiobjective decision making: Theory and methodology, 1st ed., Dover Publications, 2008.
-  R. H. C. Takahashi, Otimização Escalar e Vetorial, 2007. Disponível em:
<http://www.mat.ufmg.br/~taka/>
-  J.-S. Roger Jang, C.-T. Sun, E. Mizutani, Neuro-Fuzzy and Soft Computing: A Computational Approach to Learning and Machine Intelligence, Matlab Curriculum Series, Prentice Hall, 1997.
-  P. Prodanovic and S. P. Simonovic, *Fuzzy Compromise Programming for Group Decision Making*, IEEE Transactions on Systems, Man, and Cybernetics – Part A: Systems and Humans, 33:3, p. 358–365, May 2003.